

Wahrscheinlichkeit

Grundbegriffe

Def 1.2 - Grundraum: Der Ereignisraum oder Grundraum (sample space) $\Omega \neq \emptyset$ ist die Menge aller möglichen Ergebnisse des betrachteten Zufallsexperiments. Die Elemente $\omega \in \Omega$ heissen Elementarereignisse oder Ausgänge des Experiments (outcomes).
Def 1.4 - Potenzmenge und Ereignisse: Die Potenzmenge (power set) von Ω , $\mathcal{P}(\Omega)$ oder 2^Ω , ist die Menge aller Teilmengen von Ω . Ein prinzipielles Ereignis (event) ist eine Teilmenge $A \subseteq \Omega$, also eine Kollektion von Elementarereignissen. Die Klasse aller (beobachtbaren) Ereignisse bezeichnen wir mit \mathcal{F} . Das ist eine Teilmenge der Potenzmenge von Ω .
Note Berechnungen: Es gilt immer $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B]$ (Siebformel)
Def 1.5 - σ -Algebra : Ein Mengensystem $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ nennt man eine σ -Algebra (manchmal σ -field), wenn

- $\Omega \in \mathcal{F}$,
- für jedes $A \in \mathcal{F}$ auch das Komplement $A^c \in \mathcal{F}$ ist,
- für jede Folge $(A_n)_{n \in \mathbb{N}}$ mit $A_n \in \mathcal{F}, n \in \mathbb{N}$, auch die Vereinigung $\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{F}$ ist.

Def 1.9. (Wahrscheinlichkeitsmass): Sei Ω ein Grundraum und sei \mathcal{F} eine σ -Algebra. Eine Abbildung

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1], \text{ mit } A \mapsto \mathbb{P}[A]$$

heisst Wahrscheinlichkeitsmass (probability measure) auf (Ω, \mathcal{F}) , wenn die folgenden Axiome erfüllt sind,

- Normiertheit: $\mathbb{P}[\Omega] = 1$,
- σ -Additivität: $\mathbb{P}[\bigcup_{n \in \mathbb{N}} A_n] = \sum_{n=1}^\infty \mathbb{P}[A_n]$ für paarweise disjunkte Mengen A_n , d.h. $A_n \cap A_m = \emptyset$ für alle $n \neq m$.

Pro 1.10: Für ein Wahrscheinlichkeitsmass \mathbb{P} auf (Ω, \mathcal{F}) und Mengen $A, B \in \mathcal{F}$ gelten folgende Aussagen:

- $\mathbb{P}[A^c] = 1 - \mathbb{P}[A]$, und insbesondere $\mathbb{P}[\emptyset] = 0$.
- Monotonie: wenn $A \subseteq B$, dann $\mathbb{P}[A] \leq \mathbb{P}[B]$,
- Additionsregel:
 $\mathbb{P}[A] + \mathbb{P}[B] = \mathbb{P}[A \cup B] - \mathbb{P}[A \cap B]$

Def Definition 1.12. (Wahrscheinlichkeitsraum): Sei Ω ein Grundraum, \mathcal{F} eine σ -Algebra und \mathbb{P} ein Wahrscheinlichkeitsmass auf (Ω, \mathcal{F}) . Das Tripel $(\Omega, \mathcal{F}, \mathbb{P})$ heisst Wahrscheinlichkeitsraum.
Def 1.14. (Laplace Modell) : Sei $\Omega = \{\omega_1, \dots, \omega_N\}$ mit $|\Omega| = N$ ein endlicher Grundraum. $(\Omega, \mathcal{F}, \mathbb{P})$ heisst Laplace Modell auf Ω , wenn

- $\mathcal{F} = \mathcal{P}(\Omega)$
- \mathbb{P} ist die diskrete Gleichverteilung auf Ω , d.h. alle Elementarereignisse sind gleich wahrscheinlich, $p_1 = p_2 = \dots = p_N = \frac{1}{N}$. Insbesondere gilt für beliebige $A \subseteq \Omega$.

$$\mathbb{P}[A] = \frac{|A|}{|\Omega|} = \frac{\text{Anzahl Elementarereignisse in } A}{\text{Anzahl Elementarereignisse in } \Omega}.$$

Def 1.22. (Bedingte Wahrscheinlichkeit) : Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Seien A, B zwei Ereignisse mit $\mathbb{P}[B] > 0$. Wir definieren die bedingte Wahrscheinlichkeit von A gegeben B (conditional probability) (d.h. unter der Bedingung, dass B eintritt) wie folgt,

$$\mathbb{P}[A | B] := \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}$$

S 1.25. : Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Sei B ein Ereignis mit positiver Wahrscheinlichkeit. Dann ist $\mathbb{P}^* : \mathcal{F} \rightarrow [0, 1]$ definiert durch

$$A \mapsto \mathbb{P}^*[A] := \mathbb{P}[A | B]$$

wieder ein Wahrscheinlichkeitsmass auf (Ω, \mathcal{F}) .
S 1.29. (Satz von der totalen Wahrscheinlichkeit) : Sei B_1, \dots, B_N mit $\mathbb{P}[B_n] > 0$ für jedes $1 \leq n \leq N$ eine Partition des Grundraums Ω , d.h. $\bigcup_{n=1}^N B_n = \Omega$ mit $B_n \cap B_m = \emptyset$ für $n \neq m$. Dann gilt für alle $A \in \mathcal{F}$,

$$\mathbb{P}[A] = \sum_{n=1}^N \mathbb{P}[A | B_n] \mathbb{P}[B_n]$$

Das bedeutet insbesondere

$$\mathbb{P}[B] = \mathbb{P}[B | A] \cdot \mathbb{P}[A] + \mathbb{P}[B | A^c] \cdot \mathbb{P}[A^c]$$

S 1.32. (Satz von Bayes) : Sei $B_1, \dots, B_N \in \mathcal{F}$ eine Partition von Ω mit $\mathbb{P}[B_n] > 0$ für alle n . Für jedes Ereignis A mit $\mathbb{P}[A] > 0$ und jedes $n \in \{1, \dots, N\}$ gilt

$$\mathbb{P}[B_n | A] = \frac{\mathbb{P}[A | B_n] \mathbb{P}[B_n]}{\sum_{k=1}^N \mathbb{P}[A | B_k] \mathbb{P}[B_k]}.$$

Unabhängigkeit

Def 1.35. (Unabhängigkeit zweier Ereignisse) : Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Zwei Ereignisse A und B heissen (stochastisch) unabhängig, falls

$$\mathbb{P}[A \cap B] = \mathbb{P}[A] \mathbb{P}[B]$$

Pro Proposition 1.37.: Seien $A, B \in \mathcal{F}$ zwei Ereignisse mit $\mathbb{P}[A], \mathbb{P}[B] > 0$ Dann sind die folgenden Aussagen äquivalent:

- $\mathbb{P}[A \cap B] = \mathbb{P}[A] \mathbb{P}[B]$, A und B sind unabhängig,
- $\mathbb{P}[A | B] = \mathbb{P}[A]$, Eintreten von B hat keinen Einfluss auf A ,

- $\mathbb{P}[B | A] = \mathbb{P}[B]$, Eintreten von A hat keinen Einfluss auf B .

Def 1.40. (Unabhängigkeit) : Sei I eine beliebige Indexmenge. Eine Familie von Ereignissen $(A_i)_{i \in I}$ heisst (stochastisch) unabhängig, wenn für alle endlichen Teilmengen $J \subset I$ gilt:

$$\mathbb{P}\left[\bigcap_{j \in J} A_j\right] = \prod_{j \in J} \mathbb{P}[A_j].$$

Note :

- $\mathbb{P}(A) \in \{0, 1\} \implies A$ zu jedem Ereignis unabhängig
- A zu sich selbst unabhängig $\implies \mathbb{P}(A) \in \{0, 1\}$
- A, B unabhängig $\implies A, B^c$ unabhängig
- $\mathbb{P}[B | A^c] = 1 - \mathbb{P}[B^c | A^c]$

Zuallsvariablen

Allgemein

Def 3.4.: Sei $A \in \mathcal{F}$ ein Ereignis. Wir sagen A tritt \mathbb{P} -fast sicher (\mathbb{P} -f.s.) ein, falls $\mathbb{P}[A] = 1$. Im Englischen sagen wir \mathbb{P} -almost surely (P.a.s.). Wenn klar ist, welches Wahrscheinlichkeitsmass \mathbb{P} gemeint ist, kürzen wir ab und schreiben einfach fast sicher (f.s.).
S 2.21. (Gruppierungen von Zufallsvariablen) : Seien X_1, \dots, X_n unabhängige Zufallsvariablen. Seien $1 \leq i_1 < i_2 < \dots < i_k \leq n$ Indexe und $\varphi_1, \dots, \varphi_k$ Abbildungen. Dann sind $Y_1 := \varphi_1(X_{i_1}, \dots, X_{i_1}), Y_2 := \varphi_2(X_{i_1+1}, \dots, X_{i_2}), \dots, Y_k := \varphi_k(X_{i_1}, \dots, X_{i_k})$ unabhängig.
Def 2.22. (Unabhängig und identisch verteilt) : Eine Folge von Zufallsvariablen X_1, X_2, \dots heisst

- unabhängig falls X_1, \dots, X_n für alle $n \in \mathbb{N}$ unabhängig sind,
- unabhängig und identisch verteilt (u.i.v.), falls sie unabhängig ist und die Zufallsvariablen dieselbe Verteilungsfunktion haben, d.h. für alle $k, \ell \in \mathbb{N}$ gilt $F_{X_k} = F_{X_\ell}$.
- Im Englischen sagt man independent and identically distributed und benutzt die Abkürzung i.i.d., die auch wir in dieser Vorlesung benutzen werden.

Def 3.7. (Diskrete Zufallsvariablen) : Eine Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ heisst diskret, falls eine endliche oder abzählbare Menge $W \subset \mathbb{R}$ existiert, sodass $\mathbb{P}[X \in W] = 1$, wenn also die Werte von X fast sicher in W liegen.

Def 2.1. (Zufallsvariable) : Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Eine (reellwertige) Zufallsvariable (Z.V.) ist eine Abbildung $X : \Omega \rightarrow \mathbb{R}$, sodass für alle $x \in \mathbb{R}$ gilt,

$$\{\omega \in \Omega | X(\omega) \leq x\} \in \mathcal{F}.$$

Gewichtsfunktion (pmf)

Def 3.9. (Gewichtsfunktion) : Für eine diskrete Zufallsvariable X mit Wertebereich $W(X) = \{x_1, x_2, \dots\}$ und den dazugehörigen Wahrscheinlichkeiten $\{p_1, p_2, \dots\}$ definieren wir die Gewichtsfunktion oder diskrete Dichte von X als

$$p_X : W(X) \rightarrow [0, 1] \quad \text{mit} \quad p_X(x_k) := \mathbb{P}[X = x_k] = p_k$$

Die Zahlenfolge $\{p_X(x_k)\}_{x_k \in W(X)}$ nennen wir auch Verteilung von X .

Pro 3.10. : Die Gewichtsfunktion p_X einer diskreten Zufallsvariablen X hat folgende Eigenschaften:

- Für alle $x_k \in W(X)$ gilt $p_X(x_k) \in [0, 1]$.
- Die Wahrscheinlichkeiten addieren sich zu 1 ,
$$\sum_{x_k \in W(X)} p_X(x_k) = \mathbb{P}[X \in W(X)] = 1$$

Note Verhältnis cdf/pmf: Es gilt:

$$f_X(x) = \frac{d}{dx} F_X(x)$$

Umkehrung stimmt nicht!

Verteilungsfunktion (cdf)

S 3.12. : Sei X eine diskrete Zufallsvariable mit Werten in W und Gewichtsfunktion p_X . Dann ist die Verteilungsfunktion von X gegeben durch

$$F_X(x) = \mathbb{P}[X \leq x] = \sum_{\substack{y \leq x \\ y \in W}} p_X(y)$$

Def 2.10. (Verteilungsfunktion): Sei X eine reellwertige Zufallsvariable auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$. Die Verteilungsfunktion von X ist die Funktion $F_X : \mathbb{R} \rightarrow [0, 1]$, definiert durch

$$F_X(x) := \mathbb{P}[X \leq x]$$

Pro 2.12: Sei X eine reellwertige Zufallsvariable und seien $a < b$ zwei reelle Zahlen. Dann gilt

$$\mathbb{P}[a < X \leq b] = F_X(b) - F_X(a).$$

S 2.13. (Eigenschaften von Verteilungsfunktionen) : Sei X eine Zufallsvariable auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$. Die Verteilungsfunktion $F_X : \mathbb{R} \rightarrow [0, 1]$ von X erfüllt folgende Eigenschaften:

- F_X ist monoton wachsend.
- F_X ist rechtsstetig, d.h. für alle $x \in \mathbb{R}$ gilt $F_X(x) = \lim_{h \searrow 0} F_X(x + h)$.
- Es gelten die Grenzwerte $\lim_{x \rightarrow -\infty} F_X(x) = 0$ und $\lim_{x \rightarrow \infty} F_X(x) = 1$.

Note :

1. Wenn F_X in einem Punkt $a \in \mathbb{R}$ nicht stetig ist, dann ist die ”Sprunghöhe”
 $F_X(a) - F_X(a-)$ gleich der Wahrscheinlichkeit $\mathbb{P}(X = a)$.
2. Falls F_X stetig in einem Punkt $a \in \mathbb{R}$, dann gilt $\mathbb{P}(X = a) = 0$.

Def 2.16. (Gemeinsame Verteilungsfunktion) :
Seien X_1, \dots, X_n Zufallsvariablen. Die gemeinsame Verteilungsfunktion von X_1, \dots, X_n (joint cumulative distribution function) ist die Abbildung $F : \mathbb{R}^n \rightarrow [0, 1]$ definiert durch

$(x_1, \dots, x_n) \mapsto F(x_1, \dots, x_n) = \mathbb{P}[X_1 \leq x_1, \dots, X_n \leq x_n]$

Def 2.18. (Unabhängigkeit): Seien X_1, \dots, X_n Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$. Dann heissen X_1, \dots, X_n unabhängig, wenn für alle $x_1, \dots, x_n \in \mathbb{R}$ gilt

$\mathbb{P}[X_1 \leq x_1, \dots, X_n \leq x_n] = \mathbb{P}[X_1 \leq x_1] \cdot \dots \cdot \mathbb{P}[X_n \leq x_n]$

und somit auch

$F_{X_1, X_2, \dots}(X_1, X_2, \dots) = F_{X_1}(x_1)F_{X_2}(x_2) \dots$

Def 3.37. (Stetig verteilte Zufallsvariablen):
Eine Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ heisst stetig, wenn eine nicht-negative Funktion $f_X : \mathbb{R} \rightarrow \mathbb{R}_+$ existiert, sodass die Verteilungsfunktion F_X dargestellt werden kann als

$F_X(x) = \int_{-\infty}^x f_X(t)dt.$

Wir nennen f_X die Dichte(-funktion) von X (probability density function (*pdf*)).
Def 3.38. (Stückweise stetig differenzierbare Funktionen): Im Kontext von \mathbb{R} sagt man oft, dass ein Objekt eine Eigenschaft stückweise (piecewise) erfüllt, wenn sie die Eigenschaft auf einer Partition des Definitionsbereichs erfüllt. Wir sagen, eine Funktion f ist stückweise stetig differenzierbar, wenn es eine Partition $-\infty = x_0 < x_1 < \dots < x_{n-1} < x_n = \infty$ gibt, sodass f auf jedem Intervall (x_i, x_{i+1}) stetig differenzierbar ist.
S 3.39: Sei X eine Zufallsvariable und sei ihre Verteilungsfunktion F_X stetig und stückweise stetig differenzierbar auf einer Partition $-\infty = x_0 < x_1 < \dots < x_{n-1} < x_n = \infty$. Dann ist X eine stetige Zufallsvariable und die Dichtefunktion f_X kann wie folgt konstruiert werden,

$f_X(x) = \begin{cases} F_X'(x) & \exists k \in \{0, \dots, n-1\} : x \in (x_k, x_{k+1}) \\ a_k & x \in \{x_1, \dots, x_{n-1}\}, \end{cases}$

wobei die Werte a_k beliebig gewählt werden dürfen. In anderen Worten, es gilt $f_X(x) = F_X'(x)$ in allen Stetigkeitspunkten x von f_X .

Inverse

Def 2.30. (Verallgem einerte inverse Verteilungsfunktion): Die verallgemeinerte inverse Verteilungsfunktion von F ist eine Abbildung $F^{-1} : (0, 1) \rightarrow \mathbb{R}$ definiert durch

$F^{-1}(\alpha) = \inf\{x \in \mathbb{R} \mid F(x) \geq \alpha\}.$

Nach Definition des Infimums und unter Verwendung der Rechtsstetigkeit von F gilt für jedes $x \in \mathbb{R}$ und $\alpha \in (0, 1)$, dass

$F^{-1}(\alpha) \leq x \iff \alpha \leq F(x).$

S 2.31. (Inversionsmethode) : Sei $F : \mathbb{R} \rightarrow [0, 1]$ eine Abbildung mit den Eigenschaften (i)-(iii) aus Satz 2.13. Sei $U \sim \mathcal{U}([0, 1])$. Dann hat die Zufallsvariable $X := F^{-1}(U)$ die Verteilungsfunktion F .

Zusammengesetzte

Ex : Sei X mit F_X gegeben und $Y \sim \phi(X)$. Dann kann $F_Y(y)$ berechnen mit:

1. Schreibe $F_Y(y) = \mathbb{P}[X \leq \phi^{-1}(y)]$ (Falls quadratisch: $\mathbb{P}[-\sqrt{} \leq X \leq \sqrt{}])$
2. Finde Grenzen: $F_Y(y) \stackrel{!}{=} F_X(x) = 0, 1$
3. Schreibe $F_Y(y) = \begin{cases} 0 & x < c_0 \\ F_X(\phi^{-1}(y)) & 0 \leq x \leq 1 \\ 1 & x > c_1 \end{cases}$

Verteilungen

Bernoulli ($X \sim \text{Ber}(p)$)

Def 2.24. (Bernoulli) : Sei $p \in [0, 1]$. Eine Zufallsvariable X heisst Bernoulli Zufallsvariable mit Parameter p , wenn gilt

$\mathbb{P}[X = 0] = 1 - p \quad \text{und} \quad \mathbb{P}[X = 1] = p.$

S 2.26. (Existenzsatz von Kolmogorov): Es existiert ein Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ und eine unendliche Folge von unabhängig und gleichverteilte Bernoulli Zufallsvariablen X_1, X_2, \dots auf $(\Omega, \mathcal{F}, \mathbb{P})$ mit Parameter $\frac{1}{2}$.
Note MLE:

1. $\ell = \sum_{i=1}^n (k_i \log(p) + (1 - k_i) \log(1 - p))$
2. $\frac{\partial \ell}{\partial p} = \frac{1}{p} \sum_{i=1}^n k_i - \frac{1}{1-p} \sum_{i=1}^n (1 - k_i)$
3. $T_{MLE} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
4. Bias(T_{MLE}) = 0 somit Erwartungstreu
5. Konsistent

Note Momenterzeugende:

$M_X(t) = \mathbb{E}[e^{tX}]$

Da X die Werte 0 und 1 annimmt,

$M_X(t) = e^{t \cdot 0} \cdot P(X = 0) + e^{t \cdot 1} \cdot P(X = 1)$

$M_X(t) = e^0 \cdot (1 - p) + e^t \cdot p$

$M_X(t) = (1 - p) + pe^t$

Binomial ($X \sim \text{Bin}(n, p)$)

Def Binomialverteilung:
Wiederholung von n unabhängigen Bernoulli-Experimenten mit gleichem Parameter p .

$p(k) := \mathbb{P}(X = k) = \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k}$

mit $\forall k \in \{0, 1, \dots, n\}$
Note Eigenschaften: Es gilt

1. Für $X_n \sim \text{Bin}(n, \frac{\lambda}{n})$ gilt $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \mathbb{P}(Y = k)$ wobei $Y \sim \text{Poisson}(\lambda)$.

Proof :

1. $P[X_n = k] = \binom{n}{k} \left(1 - \frac{1}{n}\right)^{n-k} \frac{1}{n^k} = \frac{n!}{k!(n-k)!} \frac{1}{n^k} \left(1 - \frac{1}{n}\right)^n \left(1 - \frac{1}{n}\right)^{-k}.$ Nun gilt, $\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1}$ und $\left(1 - \frac{1}{n}\right)^{-k} \rightarrow 1$ wenn $n \rightarrow \infty$, und $\frac{n!}{k!(n-k)!} \frac{1}{n^k} \rightarrow 1$, da $\frac{n!}{n^k(n-k)!} = \frac{n(n-1) \dots (n-k+1)}{n^k}$, und $\frac{(n-k+1)^k}{n^k} \leq \frac{n(n-1) \dots (n-k+1)}{n^k} \leq \frac{n^k}{n^k}$, wobei der linke und rechte Ausdruck jeweils Grenzwert 1 haben. Schliesslich, $\lim_{n \rightarrow \infty} P[X_n = k] = \frac{1}{k!} e^{-1}$, und $X \sim \text{Poi}(1)$ verteilt ist.

Note MLE:

1. $\ell = k \log(p) + (N - k) \log(1 - p) + \log\left(\binom{N}{k}\right)$
2. $\frac{\partial \ell}{\partial p} = \frac{k}{p} - \frac{N-k}{1-p},$
 $\frac{\partial \ell}{\partial n} = k \log(p) + (N - k) \log(1 - p) + \frac{\partial}{\partial N} \log\left(\binom{N}{k}\right)$
3. $T_{MLE,p} = \frac{k}{N}$, $T_{MLE,n}$ hat keine geschlossene Form
4. Bias($T_{MLE,p}$) = 0 somit Erwartungstreu, Bias($T_{MLE,n}$) schwer zu berechnen :/
5. Konsistent

Note Momenterzeugende:

$M_X(t) = \mathbb{E}[e^{tX}]$
 $= \sum_{k=0}^n e^{tk} \cdot P(X = k)$
 $= \sum_{k=0}^n e^{tk} \cdot \binom{n}{k} p^k (1 - p)^{n-k}$
 $= \sum_{k=0}^n \binom{n}{k} (pe^t)^k (1 - p)^{n-k}$
 $= \left((1 - p) + pe^t\right)^n$

Geometrisch ($X \sim \text{Geo}(p)$)

Def Geometrische Verteilung:
Warten auf den 1-ten Erfolg.

$p(k) := \mathbb{P}(X = k) = (1 - p)^{k-1} \cdot p \quad \forall k \in \mathbb{N} \setminus \{0\}$

Note Eigenschaften:

1. Die Verteilung erfüllt Gedächtnislosigkeit:

$P[X > t + s \mid X > s] = P[X > t]$

Proof :

1. $P[Z > n + k \mid Z > k] = \frac{P[Z > n+k, Z > k]}{P[Z > k]} = \frac{P[Z > n+k]}{P[Z > k]} = \frac{(1-q)^{n+k}}{(1-q)^k} = (1 - q)^n = P[Z > n]$

Note MLE:

1. $\ell = n \log(p) + \sum_{i=1}^n (x_i - 1) \log(1 - p)$
2. $\frac{\partial \ell}{\partial p} = \frac{n}{p} - \frac{\sum_{i=1}^n (x_i - 1)}{1-p}$
3. $T_{MLE} = \frac{1}{\bar{X}} = \frac{n}{\sum_{i=1}^n x_i}$
4. Bias(T_{MLE}) > 0 somit nicht Erwartungstreu

5. Konsistent

Note Momenterzeugende:

$M_X(t) = \mathbb{E}[e^{tX}]$
 $= \sum_{k=0}^{\infty} e^{tk} \cdot P(X = k)$
 $= \sum_{k=0}^{\infty} e^{tk} \cdot (1 - p)^k \cdot p$
 $= p \sum_{k=0}^{\infty} (e^t(1 - p))^k$
 $= p \cdot \frac{1}{1 - e^t(1 - p)}$
 $= \frac{p}{1 - (1 - p)e^t}$

Poisson ($X \sim \text{Poi}(\lambda)$)

Def Poisson-Verteilung:

Grenzwert der Binomialverteilung für grosse n und kleine p .

$$p(k) := \mathbb{P}(X = k) = \frac{\lambda^k}{k!} \cdot e^{-\lambda} \quad \forall k \in_0, \lambda > 0$$

Note Eigenschaften:

1. Seien $X_1 \sim \text{Poisson}(\lambda_1)$ und $X_2 \sim \text{Poisson}(\lambda_2)$ unabhängig. Dann gilt $(X_1 + X_2) \sim \text{Poisson}(\lambda_1 + \lambda_2)$.

2. Seien $X, Y \sim \text{Poi}(\lambda), \text{Poi}(\mu)$ Es gilt:
 $P[X = k \mid X + Y = n] = \binom{n}{k} \left(\frac{\lambda}{\lambda + \mu}\right)^k \left(1 - \frac{\lambda}{\lambda + \mu}\right)^{n-k} = \text{bin}(n, \frac{\lambda}{\lambda + \mu})$

Proof :

1. Für $k \in \mathbb{N}_0$ $P[X + Y = k] = \sum_{l=0}^{\infty} P[X + Y = k, Y = l]$ **(Totale Wahrscheinlichkeit)**
 $= \sum_{l=0}^k P[X + Y = k, Y = l] = \sum_{l=0}^k P[X = k - l, Y = l]$
 $= \sum_{l=0}^k P[X = k - l] \cdot P[Y = l]$
 $= \sum_{l=0}^k e^{-\lambda} \frac{\lambda^{k-l}}{(k-l)!} \cdot e^{-\mu} \frac{\mu^l}{l!}$
 $= e^{-(\lambda + \mu)} \frac{1}{k!} \sum_{l=0}^k \binom{k}{l} \lambda^{k-l} \mu^l$
 $= e^{-(\lambda + \mu)} \frac{1}{k!} \sum_{l=0}^k \binom{k}{l} \lambda^{k-l} \mu^l = e^{-(\lambda + \mu)} \frac{(\lambda + \mu)^k}{k!}$ (binomischer Satz)

2. Sei $k \in \{0, 1, \dots, n\}$:
 $P[X = k \mid X + Y = n] = \frac{P[X=k, X+Y=n]}{P[X+Y=n]} = \frac{P[X=k, Y=n-k]}{P[X+Y=n]} = \frac{P[X=k]P[Y=n-k]}{P[X+Y=n]}$ (Def. bedingte Wahrscheinlichkeit, Unabhängigkeit von X, Y)
 $= \frac{e^{-\lambda} \frac{\lambda^k}{k!} \cdot e^{-\mu} \frac{\mu^{n-k}}{(n-k)!}}{e^{-(\lambda + \mu)} \frac{(\lambda + \mu)^n}{n!}} = \frac{e^{-\lambda} e^{-\mu}}{e^{-(\lambda + \mu)}} \cdot \frac{n!}{k!(n-k)!}$
 $\frac{\lambda^k \mu^{n-k}}{(\lambda + \mu)^n} = \binom{n}{k} \cdot \frac{\lambda^k}{(\lambda + \mu)^k} \cdot \frac{\mu^{n-k}}{(\lambda + \mu)^{n-k}} = \binom{n}{k} \cdot \left(\frac{\lambda}{\lambda + \mu}\right)^k \cdot \left(\frac{\lambda + \mu - \lambda}{\lambda + \mu}\right)^{n-k} = \binom{n}{k} \cdot \left(\frac{\lambda}{\lambda + \mu}\right)^k \cdot (1 - \frac{\lambda}{\lambda + \mu})^{n-k}$ (Umformen)

Note MLE:

1. $\ell = \sum_{i=1}^n (x_i \log(\lambda) - \lambda - \log(x_i!))$

2. $\frac{\partial \ell}{\partial \lambda} = \frac{1}{\lambda} \sum_{i=1}^n x_i - n$

3. $T_{MLE} = \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$

4. Bias(T_{MLE}) = 0 somit Erwartungstreu

5. Konsistent

Proof Log-Likelihood: Die log-Likelihood-Funktion für die Poissonverteilung lautet

$$\begin{aligned} \log L(k_1, \dots, k_n; \lambda) &= \log \left(\prod_{i=1}^n e^{-\lambda} \frac{\lambda^{k_i}}{k_i!} \right) \\ &= \sum_{i=1}^n \log \left(e^{-\lambda} \frac{\lambda^{k_i}}{k_i!} \right) \\ &= -n\lambda + \log(\lambda) \sum_{i=1}^n k_i - \sum_{i=1}^n \log(k_i!) \end{aligned}$$

Die Ableitung nach λ ist

$$\frac{\partial}{\partial \lambda} \log L(k_1, \dots, k_n; \lambda) = -n + \frac{1}{\lambda} \sum_{i=1}^n k_i$$

und diese ist 0 für

$$\lambda = \frac{1}{n} \sum_{i=1}^n k_i.$$

Also ist der ML-Schätzer für λ gleich $T = \frac{1}{n} \sum_{i=1}^n X_i$.
Note Momenterzeugende:

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= \sum_{k=0}^{\infty} e^{tk} \cdot P(X = k) \\ &= \sum_{k=0}^{\infty} e^{tk} \cdot \frac{\lambda^k e^{-\lambda}}{k!} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} \\ &= e^{-\lambda} \cdot e^{\lambda e^t} \\ &= e^{\lambda(e^t - 1)} \end{aligned}$$

Gleichverteilt ($X \sim \mathcal{U}([a, b])$)

Def 2.27. (Gleichverteilt): Eine Zufallsvariable U heisst gleichverteilt auf $[0, 1]$, wir schreiben $U \sim \mathcal{U}([0, 1])$, falls ihre Verteilungsfunktion gegeben ist durch

$$F_U(x) = \begin{cases} 0 & x < 0 \\ x & 0 \leq x \leq 1 \\ 1 & x > 1 \end{cases}$$

S 2.28.: Die Abbildung $X : \Omega \rightarrow [0, 1]$ definiert in Gleichung $X(\omega) := \sum_{n=1}^{\infty} 2^{-n} X_n(\omega)$ ist eine gleichverteilte Zufallsvariable auf $[0, 1]$.
2.29. (Binärdarstellung) Jedes $x \in [0, 1]$ kann eindeutig in der Form

$$x = \sum_{n=1}^{\infty} 2^{-n} x_n$$

dargestellt werden, wobei für alle $n \in \mathbb{N}$ gilt, $x_n \in \{0, 1\}$, und für jedes $N \in \mathbb{N}$ gibt es ein $k > N$, sodass $x_k = 0$ (also die Folge "endet" nicht in unendlichen vielen 1-en.) Die Folge $\{x_n\}_{n \in \mathbb{N}}$ heisst Binärdarstellung von x und wir schreiben $x = (.x_1x_2x_3\dots)_2$.

S 3.3. (Wahrscheinlichkeit eines Punktes): Sei $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable mit Verteilungsfunktion F . Für jedes $x \in \mathbb{R}$ gilt $\mathbb{P}[X = x] = F(x) - F(x-)$
Ex : Seien $X, Y, Z \sim \mathcal{U}(0, 1)$. Es gilt:
 $\mathbb{P}[X > Y] = \int \int_{(x,y) \in [0,1]^2} 1_{(x>y)} f_{X,Y}(x,y) dx dy = \int_0^1 \int_0^x 1 dy dx = \int_0^1 x dx = \frac{1}{2}$
 $\mathbb{P}[X > Y, X > Z] = \int \int \int_{(x,y,z) \in [0,1]^3} 1_{(x>y \wedge x>z)} f_{X,Y,Z}(x,y,z) dz dy dx = \int_0^1 \int_0^x \int_0^x 1 dz dy dx = \int_0^1 \int_0^x x dy dx = \int_0^1 x^2 dx = \frac{1}{3}$
 $\mathbb{P}[X > Y \mid X > Z] = \frac{\mathbb{P}[X>Y, X>Z]}{\mathbb{P}[X>Z]} = \frac{1}{3} \cdot \frac{3}{2} = \frac{1}{2}$

Ex : Seien $X \sim \mathcal{U}(a, b)$ und $X \sim \mathcal{U}(c, d)$ Es gilt
 $\mathbb{P}[X > Y] = \frac{c-a}{b-a} + \frac{(b-c)^2}{2(b-a)(d-c)}$. Des weiteren:
 $f_{X+Y}(z) = \begin{cases} \frac{z-(a+c)}{(b-a)(d-c)} & \text{if } a+c \leq z < a+d \\ \frac{1}{(b-a)(d-c)} & \text{if } a+d \leq z < b+c \\ \frac{(b+a)-z}{(b-a)(d-c)} & \text{if } b+c \leq z < b+d \end{cases}$

Note MLE:

1. $\ell = -n \log(b - a)$ für $a \leq \min(x_1, x_2, \dots, x_n)$ und $b \geq \max(x_1, x_2, \dots, x_n)$, ansonsten $\ell = -\infty$

2. $\frac{\partial \ell}{\partial a} = \frac{n}{a-b}, \quad \frac{\partial \ell}{\partial b} = \frac{n}{b-a}$

3. $T_{MLE,a} = \min(x_1, x_2, \dots, x_n)$,
 $T_{MLE,b} = \max(x_1, x_2, \dots, x_n)$

4. Bias($T_{MLE,a}$) = $\frac{a-b}{n+1}$, Bias($T_{MLE,b}$) = $\frac{b-a}{n+1}$, somit beide nicht Erwartungstreu

5. Konsistent

Note Momenterzeugende:

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= \int_a^b e^{tx} \cdot \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \int_a^b e^{tx} dx \\ &= \frac{1}{b-a} \left[\frac{e^{tx}}{t} \right]_a^b \\ &= \frac{1}{b-a} \left(\frac{e^{tb} - e^{ta}}{t} \right) \\ &= \frac{e^{tb} - e^{ta}}{t(b-a)} \end{aligned}$$

Exponential ($X \sim \text{Exp}(\lambda)$)

Note Eigenschaften:

1. Die Exponential-Verteilung erfüllt Gedächtnislosigkeit:

$$P[X > t + s \mid X > s] = P[X > t]$$

2. Seien $X, Y \sim \text{Exp}(\lambda_X), \text{Exp}(\lambda_Y)$ Es gilt

$$\mathbb{P}[X > Y] = \frac{\lambda_Y}{\lambda_X + \lambda_Y}$$

Proof :

1. $\mathbb{P}[T > s + t \mid T > s] = \frac{\mathbb{P}[T>s+t \cap T>s]}{\mathbb{P}[T>s]} = \frac{\mathbb{P}[T>s+t]}{\mathbb{P}[T>s]} = \frac{1 - \mathbb{P}[T \leq s+t]}{1 - \mathbb{P}[T \leq s]} = \frac{1 - (1 - e^{-\alpha(s+t)})}{1 - (1 - e^{-\alpha s})} = \frac{e^{-\alpha(s+t)}}{e^{-\alpha s}} = e^{-\alpha t} = 1 - \mathbb{P}[T \leq t] = \mathbb{P}[T > t]$
2. $\mathbb{P}[Z > Y] = \int_{-\infty}^{\infty} \underbrace{\mathbb{P}[Z > y]}_{=e^{-\mu y}} \cdot \underbrace{f_Y(y)}_{=\lambda e^{-\lambda y}} dy = \int_0^{\infty} e^{-\mu y} \lambda e^{-\lambda y} dy = \int_0^{\infty} \lambda e^{-\lambda y} e^{-\mu y} dy = -\frac{\lambda}{\lambda + \mu} \int_{u(0)}^{u(\infty)} e^u du = -\frac{\lambda}{\lambda + \mu} [e^{-(\lambda + \mu)y}]_0^{\infty} = -\frac{\lambda}{\lambda + \mu} (0 - 1) = \frac{\lambda}{\lambda + \mu}$

Note MLE:

1. $\ell = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$

2. $\frac{\partial \ell}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i$

3. $T_{MLE} = \frac{1}{\bar{X}} = \frac{n}{\sum_{i=1}^n x_i}$

4. Bias(T_{MLE}) = 0 somit Erwartungstreu

5. Konsistent

Note Momenterzeugende:

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= \int_0^{\infty} e^{tx} \cdot \lambda e^{-\lambda x} dx \\ &= \lambda \int_0^{\infty} e^{(t-\lambda)x} dx \\ &= \lambda \left[\frac{e^{(t-\lambda)x}}{t-\lambda} \right]_0^{\infty} \\ &= \lambda \left(\frac{1}{t-\lambda} \right) \quad (\text{für } t < \lambda) \\ &= \frac{\lambda}{\lambda - t} \end{aligned}$$

Normal ($X \sim \mathcal{N}(\mu, \sigma^2)$)

Pro 3.49. (Standardnormalverteilung): Für $X \sim \mathcal{N}(\mu, \sigma^2)$ gilt $\frac{X-\mu}{\sigma} \sim \mathcal{N}(0, 1)$, also

$$F_X(x) = \mathbb{P}[X \leq x] = \mathbb{P}\left[\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right] = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

Note : Seien X_1, \dots, X_n unabhängige normalverteilte ZV mit Parametern $(m_1, \sigma_1^2), \dots, (m_n, \sigma_n^2)$, dann ist

$$Z = m_0 + \lambda_1 X_1 + \dots + \lambda_n X_n$$

Lem 4.21.: Für das uneigentliche Integral über die gaußsche Glockenkurve gilt

$$\int_{-\infty}^{\infty} e^{-\frac{x^2}{2\sigma^2}} dx = \sqrt{2\pi\sigma^2}$$

Note Eigenschaften:

1. $\frac{1}{n} (X_1 + \dots + X_n)^2 \sim \chi_1^2$

Proof :

1. Wir wissen, dass $X_1 + \dots + X_n$ einer Normalverteilung folgt mit $\mathbb{E}[S_n] = \mathbb{E}[X_1 + X_2 + \dots + X_n] = n \cdot \mathbb{E}[X_i] = 0, \mathbb{V}(S_n) = \mathbb{V}(X_1 + X_2 + \dots + X_n) = n \cdot \mathbb{V}(X_i) = n \cdot 1 = n$ Somit ist $S_n \sim \mathcal{N}(\mathbb{E}[S_n], \mathbb{V}[S_n]) = \mathcal{N}(0, n)$. Wir standardisieren S_n und erhalten $\frac{S_n - 0}{\sqrt{n}} \sim \mathcal{N}(0, 1)$

Dann $\chi_1^2 \sim Z^2 \sim \left(\frac{S_n}{\sqrt{n}}\right)^2$ und somit $\left(\frac{S_n}{\sqrt{n}}\right)^2 \stackrel{\text{Def}}{=} \left(\frac{X_1 + \dots + X_n}{\sqrt{n}}\right)^2 = \frac{(X_1 + \dots + X_n)^2}{n}$

Note MLE:

1. $\ell = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

2. $\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)$,
 $\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$

3. $T_{MLE,\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$,
 $T_{MLE,\sigma^2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2$

4. $\text{Bias}(T_{MLE,\mu}) = 0$, $\text{Bias}(T_{MLE,\sigma^2}) = -\frac{\sigma^2}{n}$
somit μ ist Erwartungstreu, σ^2 ist nicht Erwartungstreu

5. Konsistent

Note Momenterzeugende:

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] \\ &= \int_{-\infty}^{\infty} e^{tx} \cdot \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} e^{tx - \frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} e^{-\frac{(x^2 - 2\mu x + \mu^2) - 2\sigma^2 tx + 2\sigma^2 t\mu}{2\sigma^2}} dx \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} e^{-\frac{(x - (\mu + \sigma^2 t))^2}{2\sigma^2}} e^{\frac{\mu^2 + 2\sigma^2 t\mu - 2\sigma^2 t\mu}{2\sigma^2}} dx \\ &= e^{\mu t + \frac{1}{2}\sigma^2 t^2} \end{aligned}$$

Chi-Quadrat-Verteilung (\mathcal{X}^2)

Def : Es gilt $\chi^2 = Z_1^2 + \dots + Z_n^2$ mit $Z_1, \dots, Z_n \sim \mathcal{N}(0, 1)$

Note Eigenschaften:

- $\chi^2 = X_1^2 + X_2^2 = \text{Exp}(\frac{1}{2})$ mit $X_1, X_2 \sim \mathcal{N}(0, 1)$

Proof :

- Formel for χ^2 numerisch mit $n = 2$ ausrechnen.

Extremwertverteilt (\mathcal{X}^2)

Def : Es gilt:

$$F_{\alpha}(x) = e^{-e^{-(x-\alpha)}}$$

Note Dichtefunktion:

$$f_{\alpha}(x) = F'_{\alpha}(x) = e^{-(x-\alpha)} e^{-e^{-(x-\alpha)}}$$

Note Erwartungswert:

$$E[X] = \gamma + \alpha$$

mit $\gamma = -\int_0^{\infty} \log x e^{-x} dx$
Proof : $E[X] = \int_{\mathbb{R}} x f_{\alpha}(x) dx$
 $= \int_{\mathbb{R}} (x - \alpha) f_{\alpha}(x) dx + \alpha \int_{\mathbb{R}} f_{\alpha}(x) dx$
 $= \int_{\mathbb{R}} (x - \alpha) e^{-(x-\alpha)} e^{-e^{-(x-\alpha)}} dx + \alpha$
 $= \int_{\mathbb{R}} s e^{-s} e^{-e^{-s}} ds + \alpha$
Durch die Variablensubstitution $u = e^{-s}$ mit $s = -\log u$ und $\frac{ds}{du} = -\frac{1}{u}$ erhlt man fr das verbleibende Integral
 $\int_{\mathbb{R}} s e^{-s} e^{-e^{-s}} ds = \int_{\infty}^0 (-\log u) u e^{-u} \left(-\frac{1}{u}\right) du =$
 $= -\int_0^1 \log u e^{-u} du = \gamma$

Kompositionen

- $\mathbb{P}[X > Y] = \sum_{j=1}^n \mathbb{P}[X > Y \mid Y = j] \mathbb{P}[Y = j]$ (diskret)
- $\mathbb{P}[X > Y] = \int_{-\infty}^{\infty} \mathbb{P}[X > Y \mid Y = y] f_Y(y) dy$ (stetig)
- Sei X mit f_x eine ZV und $Y \sim aX + b$. Dann

Erwartungswert

Def 4.1. (Erwartungswert (nicht-negativ)) :
Sei $X : \Omega \rightarrow \mathbb{R}_+$ eine Zufallsvariable mit nicht-negativen Werten und Verteilungsfunktion F_X . Dann heisst

$$\mathbb{E}[X] = \int_0^{\infty} (1 - F_X(x)) dx$$

der Erwartungswert von X (expected value).
S 4.3.: Sei X eine nicht-negative Zufallsvariable. Dann gilt $\mathbb{E}[X] \geq 0$. Gleichheit gilt genau dann wenn $X = 0$ fast sicher gilt.
Def 4.4. (Allgemeiner Erwartungswert): Sei X eine reellwertige Zufallsvariable. Falls $\mathbb{E}[|X|] < \infty$, dann heisst

$$\mathbb{E}[X] = \mathbb{E}[X_+] - \mathbb{E}[X_-]$$

der Erwartungswert von X .

Diskret

S 4.8 (Erwartungswert (diskret)) : Sei $X : \Omega \rightarrow \mathbb{R}$ eine diskrete Zufallsvariable, deren Werte fast sicher in W (endlich oder abzhlbar) liegen. Dann gilt

$$\mathbb{E}[X] = \sum_{x \in W} x \cdot \mathbb{P}[X = x] = \sum_{x \in W} x p_X(x)$$

solange der Erwartungswert wohldefiniert ist. Somit gilt auch

$$\mathbb{E}[a + b \cdot X^c] = a + \sum_{x \in W} b \cdot x^c p_X(x)$$

Stetig

S 4.17. (Erwartungswert (stetig)) : Sei X eine stetige Zufallsvariable mit Dichte f_X . Dann gilt

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x) dx$$

solange das Integral absolut konvergiert, d.h. falls $\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty$. Ist das Integral nicht absolut konvergent, so existiert der Erwartungswert nicht (zumindest nicht in \mathbb{R}). Das ist vllig analog zum diskreten Fall. Es gilt ebenfalls

$$\mathbb{E}[a + b \cdot X^c] = a + \int_{-\infty}^{\infty} b \cdot x^c \cdot f_X(x) dx$$

Eigenschaften

S 4.18.: Sei X eine stetige Zufallsvariable mit Dichte f_X und sei $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ eine Abbildung. Dann gilt

$$\mathbb{E}[\varphi(X)] = \int_{-\infty}^{\infty} \varphi(x) f_X(x) dx$$

solange das Integral wohldefiniert ist.
S 4.25. (Linearitt des Erwartungswerts): Seien $X, Y : \Omega \rightarrow \mathbb{R}$ Zufallsvariablen und sei $\lambda \in \mathbb{R}$. Falls die Erwartungswerte wohldefiniert sind, gilt

$$1. \mathbb{E}[\lambda X] = \lambda \mathbb{E}[X]$$

$$2. \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y].$$

S 4.29. (Monotonie des Erwartungswerts) : Seien X, Y zwei Zufallsvariablen, sodass $X \leq Y$ f.s. gilt. Falls beide Erwartungswerte wohldefiniert sind, gilt

$$\mathbb{E}[X] \leq \mathbb{E}[Y]$$

Unabhngigkeit

S 4.30 (Erwartungswerte bei Unabhngigkeit): fr n unabhngige Zufallsvariablen X_1, \dots, X_n .
Satz 4.31. Seien X_1, \dots, X_n unabhngige Zufallsvariablen mit endlichen Erwartungswerten $\mathbb{E}[X_1], \dots, \mathbb{E}[X_n]$. Dann gilt

$$\mathbb{E}\left[\prod_{k=1}^n X_k\right] = \prod_{k=1}^n \mathbb{E}[X_k]$$

S 4.32.: Sei X eine Zufallsvariable und sei $f : \mathbb{R} \rightarrow \mathbb{R}_+$ eine Abbildung, sodass $\int_{-\infty}^{\infty} f(x) dx = 1$. Dann sind folgende Aussagen quivalent

- X ist stetig mit Dichte f ,
- fr jede stckweise stetige, beschrnkte Abbildung $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ gilt

$$\mathbb{E}[\varphi(X)] = \int_{-\infty}^{\infty} \varphi(x) f(x) dx$$

S 4.33.: Seien X, Y zwei Zufallsvariablen. Die folgenden Aussagen sind quivalent:

- X, Y sind unabhngig,
- Fr alle stckweise stetigen, beschrnkten Abbildungen $\varphi, \psi : \mathbb{R} \rightarrow \mathbb{R}$ gilt

$$\mathbb{E}[\varphi(X)\psi(Y)] = \mathbb{E}[\varphi(X)]\mathbb{E}[\psi(Y)]$$

S 4.34. : Seien X_1, \dots, X_n Zufallsvariablen. Die folgenden Aussagen sind quivalent:

- X_1, \dots, X_n sind unabhngig,
- Fr alle stckweise stetigen, beschrnkten Abbildungen $\varphi_1, \dots, \varphi_n : \mathbb{R} \rightarrow \mathbb{R}$ gilt

$$\mathbb{E}[\varphi_1(X_1) \cdot \dots \cdot \varphi_n(X_n)] = \mathbb{E}[\varphi_1(X_1)] \cdot \dots \cdot \mathbb{E}[\varphi_n(X_n)].$$

Ungleichungen

S 4.35. (Markow-Ungleichung) : Sei X eine nicht-negative Zufallsvariable und sei $g : X(\Omega) \rightarrow [0, \infty)$ eine wachsende Funktion. Fr jedes $c \in \mathbb{R}$ mit $g(c) > 0$ gilt

$$\mathbb{P}[X \geq c] \leq \frac{\mathbb{E}[g(X)]}{g(c)}$$

S 4.36. (Jensenseche Ungleichung) : Sei X eine Zufallsvariable und sei $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ eine

konvexe Funktion. Falls $\mathbb{E}[\varphi(X)]$ und $\mathbb{E}[X]$ wohldefiniert sind, gilt

$$\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$$

Cor 4.37. (Dreiecksungleichung) : Anwendung der Jensenschen Ungleichung auf $\varphi(x) = |x|$ liefert die Dreiecksungleichung,

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$$

Varianz

Def 4.38. (Varianz Standardabweichung): Sei X eine Zufallsvariable, sodass $\mathbb{E}[X^2] < \infty$. Wir definieren die Varianz von X (variance) durch

$$\mathbb{V}[X] = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

Die Wurzel der Varianz nennt man Standardabweichung von X (standard deviation) und sie wird oft mit $\sigma = \sigma_X = \sigma(X) = \sqrt{\mathbb{V}[X]}$ bezeichnet.

Eigenschaften

Pro 4.46. : Seien X_1, \dots, X_n paarweise unabhngigen Zufallsvariablen, dann gilt

$$\mathbb{V}\left[\sum_{k=1}^n X_k\right] = \sum_{k=1}^n \mathbb{V}[X_k]$$

Note :

- Sei X ein ZV, sodass $(X^2) < \infty$ und $a, b \in$:

$$\mathbb{V}(a \cdot X + b) = a^2 \cdot \mathbb{V}(X)$$

- Seien X_1, \dots, X_n paarweise unabhngig. Dann gilt

$$\mathbb{V}(X_1 + \dots + X_n) = \mathbb{V}(X_1) + \dots + \mathbb{V}(X_n)$$

Cor 4.50. (Chebyshev-Ungleichung): Sei Y eine Zufallsvariable mit endlicher Varianz. Fr jedes $c > 0$ gilt dann

$$\mathbb{P}[|Y - \mathbb{E}[Y]| \geq c] \leq \frac{\mathbb{V}[Y]}{c^2}$$

Note :

- $\text{Cov}(X, X) = \mathbb{V}(X)$
- X, Y unabhngig $\implies \text{Cov}(X, Y) = 0$ (**Die Umkehrung ist falsch!**)
- $\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2\text{Cov}(X, Y)$
- $\mathbb{V}(X) \geq 0$

Kovarianz

Def 4.51. (Kovarianz): Seien X, Y zwei Zufallsvariablen mit endlichen zweiten Momenten, $\mathbb{E}[X^2], \mathbb{E}[Y^2] < \infty$. Die Kovarianz zwischen X und Y (covariance) ist definiert als

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Note Kovarianz: Man kann die Kovarianz ebenfalls ausdrücken durch

$$\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Beweis:

$$\begin{aligned} \text{cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[(XY - \mathbb{E}[X]Y - \mathbb{E}[Y]X + \mathbb{E}[X]\mathbb{E}[Y])] \\ &\stackrel{4.25}{=} \mathbb{E}[XY] - \mathbb{E}[\mathbb{E}[X]Y] - \mathbb{E}[\mathbb{E}[Y]X] + \mathbb{E}[\mathbb{E}[X]\mathbb{E}[Y]] \\ &\stackrel{(1)}{=} \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \end{aligned}$$

Note Kolleriertheit: Es gilt:

- Wenn $\text{cov}(X, Y) > 0$, dann sind X und Y positiv korreliert.
- wenn $\text{cov}(X, Y) = 0$, dann sind X und Y unkorreliert.
- Wenn $\text{cov}(X, Y) < 0$, dann sind X und Y negativ korreliert oder antikorreliert.

Note Eigenschaften: Für die Kovarianz gilt:

- 1. **Positive Semidefinitheit:** $\text{cov}(X, X) \geq 0$,
- 2. **Symmetrie:** $\text{cov}(X, Y) = \text{cov}(Y, X)$
- 3. **Bilinearität:** $\text{cov}(aX + b, cY + d) = ac \text{cov}(X, Y)$ und $\text{cov}(X, (eY + f) + (gZ + h)) = e \text{cov}(X, Y) + g \text{cov}(X, Z)$.

Proof :

1.

$$\begin{aligned} \text{cov}(X, X) &\stackrel{4.52}{=} \mathbb{E}[X X] - \mathbb{E}[X]\mathbb{E}[X] \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \\ &\stackrel{4.40}{=} \mathbb{V}[X] \end{aligned}$$

2.

$$\begin{aligned} \text{cov}(X, Y) &\stackrel{4.52}{=} \mathbb{E}[X Y] - \mathbb{E}[X]\mathbb{E}[Y] \tag{1} \\ &= \mathbb{E}[Y X] - \mathbb{E}[Y]\mathbb{E}[X] \tag{2} \\ &\stackrel{4.52}{=} \text{cov}(Y, X) \tag{3} \end{aligned}$$

3.

Zusammengesetzte

Note Verteilung einer Ungleichung: Es gilt für beliebige ZV X, Y :

$$\mathbb{P}[X > Y] = \int_{-\infty}^{\infty} \mathbb{P}[X > y] \cdot f_Y(y) dy$$

Gemeinsame Verteilungen

S 5.3. : Eine gemeinsame Verteilung von Zufallsvariablen X_1, \dots, X_n erfüllt stets

$$\sum_{x_1 \in W_1, \dots, x_n \in W_n} p(x_1, \dots, x_n) = 1$$

Pro 5.5: Aus der gemeinsamen Gewichtsfunktion p bekommt man die gemeinsame Verteilungsfunktion via

$$\begin{aligned} F(x_1, \dots, x_n) &= \mathbb{P}[X_1 \leq x_1, \dots, X_n \leq x_n] \\ &= \sum_{y_1 \leq x_1, \dots, y_n \leq x_n} \mathbb{P}[x_1 = y_1, \dots, X_n = y_n] \\ &= \sum_{y_1 \leq x_1, \dots, y_n \leq x_n} p(y_1, \dots, y_n). \end{aligned}$$

Def 5.18. (Randverteilung) : Haben X und Y die gemeinsame Verteilungsfunktion F , so ist die Funktion $F_X : \mathbb{R} \rightarrow [0, 1]$, gegeben durch

$$x \mapsto F_X(x) = \mathbb{P}[X \leq x] = \mathbb{P}[X \leq x, Y < \infty] = \lim_{y \rightarrow \infty} F(x, y)$$

die Verteilungsfunktion der Randverteilung von X . Analog ist

$$F_Y : \mathbb{R} \rightarrow [0, 1]$$

$$y \mapsto F_Y(y) = \mathbb{P}[Y \leq y] = \mathbb{P}[X < \infty, Y \leq y] = \lim_{x \rightarrow \infty} F(x, y)$$

die Verteilungsfunktion der Randverteilung von Y .

Diskret

Def 5.1. (Gemeinsame diskrete Verteilung) : Seien X_1, \dots, X_n diskrete Zufallsvariablen, seien für $k \in \{1, \dots, n\}$ Mengen $W_k \subset \mathbb{R}$ endlich oder abzählbar, sodass $X_k \in W_k$ fast sicher gilt. Die gemeinsame Verteilung von (X_1, \dots, X_n) ist eine Familie von Wahrscheinlichkeiten

$$\{p(x_1, \dots, x_n)\}_{x_1 \in W_1, \dots, x_n \in W_n}$$

wobei $p : \mathbb{R}^n \rightarrow [0, 1]$ die gemeinsame Gewichtsfunktion bezeichnet,

$$p(x_1, \dots, x_n) = \mathbb{P}[X_1 = x_1, \dots, X_n = x_n]$$

S 5.6. (Verteilung des Bildes) : Sei $n \geq 1$ und sei $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ eine Abbildung. Seien X_1, \dots, X_n diskrete Zufallsvariablen, mit Werten jeweils in W_1, \dots, W_n (f.s.). Dann ist $Z = \varphi(X_1, \dots, X_n)$ eine diskrete Zufallsvariable, die f.s. Werte in $W = \varphi(W_1 \times \dots \times W_n)$ annimmt. Zudem ist die Verteilung von Z für alle $z \in W$ gegeben durch

$$\mathbb{P}[Z = z] = \sum_{\substack{x_1 \in W_1, \dots, x_n \in W_n \\ \varphi(x_1, \dots, x_n) = z}} \mathbb{P}[X_1 = x_1, \dots, X_n = x_n]$$

S 5.7. (Randverteilung): Seien X_1, \dots, X_n diskrete Zufallsvariablen mit gemeinsamer

Gewichtsfunktion p . Für jedes $k \in \{1, \dots, n\}$ und jedes $x \in W_k$ gilt

$$\mathbb{P}[X_k = x] = \sum_{\substack{x_\ell \in W_\ell \\ \ell \in \{1, \dots, n\} \setminus \{k\}}} p(x_1, \dots, x_{k-1}, x, x_{k+1}, \dots, x_n)$$

S 5.9. (Erwartungswert des Bildes): Seien X_1, \dots, X_n diskrete Zufallsvariablen mit gemeinsamer Verteilung $\{p(x_1, \dots, x_n)\}_{x_1 \in W_1, \dots, x_n \in W_n}$ und sei $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ eine Abbildung. Es gilt

$$\mathbb{E}[\varphi(X_1, \dots, X_n)] = \sum_{x_1, \dots, x_n} \varphi(x_1, \dots, x_n) p(x_1, \dots, x_n)$$

solange die Summe wohldefiniert ist, wobei wir hier über alle $x_1 \in W_1, \dots, x_n \in W_n$ summieren.

S 5.10. : Seien X_1, \dots, X_n diskrete Zufallsvariablen mit gemeinsamer Verteilung $\{p(x_1, \dots, x_n)\}_{x_1 \in W_1, \dots, x_n \in W_n}$. Die folgenden Aussagen sind äquivalent

- 1. X_1, \dots, X_n sind unabhängig,
- 2. für alle $x_1 \in W_1, \dots, x_n \in W_n$ gilt

$$p(x_1, \dots, x_n) = \mathbb{P}[X_1 = x_1] \cdot \dots \cdot \mathbb{P}[X_n = x_n]$$

d.h. die gemeinsame Gewichtsfunktion ist das Produkt der einzelnen Gewichtsfunktionen der Randverteilungen.

Stetig

Def 5.11. (Gemeinsame stetige Verteilung) : Sei $n \geq 1$. Wir sagen, dass die Zufallsvariablen $X_1, \dots, X_n : \Omega \rightarrow \mathbb{R}$ eine stetige gemeinsame Verteilung besitzen, falls eine Abbildung $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$ existiert, sodass für alle $a_1, \dots, a_n \in \mathbb{R}$ gilt, $\mathbb{P}[X_1 \leq a_1, \dots, X_n \leq a_n] = \int_{-\infty}^{a_1} \dots \int_{-\infty}^{a_n} f(x_1, \dots, x_n) dx_n \dots dx_1$ Die Funktion f heisst die gemeinsame Dichte von (X_1, \dots, X_n) (joint probability density function).

S 5.12.: Sei f die gemeinsame Dichte der Zufallsvariablen (X_1, \dots, X_n) . Dann gilt

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_n) dx_n \dots dx_1 = 1$$

Umgekehrt kann jeder Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$, die Gleichung oben erfüllt, ein Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ und n Zufallsvariablen X_1, \dots, X_n zugeordnet werden, sodass f die gemeinsame Dichte von X_1, \dots, X_n ist.

S 5.15. (Erwartungswert des Bildes): Sei $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ eine Abbildung. Falls X_1, \dots, X_n eine gemeinsame Dichte f besitzen, dann lässt sich der Erwartungswert der Zufallsvariable $\varphi(X_1, \dots, X_n)$ berechnen als $\mathbb{E}[\varphi(X_1, \dots, X_n)] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \varphi(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_n \dots dx_1$

S 5.21. (Unabhängigkeit von stetigen Zufallsvariablen): Seien X_1, \dots, X_n Zufallsvariablen mit Dichten f_{X_1}, \dots, f_{X_n} . Dann sind die folgenden Aussagen äquivalent,

- 1. X_1, \dots, X_n sind unabhängig,

- 2. X_1, \dots, X_n sind gemeinsam stetig mit gemeinsamer Dichte $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$,
 $f(x_1, \dots, x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n)$
 - 3. f ist die gemeinsame Dichtefunktion f ist das Produkt der einzelnen Randdichten f_{X_k} .
- Note Randdichten:** Haben X und Y eine gemeinsame Dichte $f(x, y)$, so haben auch die Randverteilungen von X und Y Dichten $f_X : \mathbb{R} \rightarrow \mathbb{R}_+$ bzw. $f_Y : \mathbb{R} \rightarrow \mathbb{R}_+$.
 $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$ und $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$
Falls bei Verteilungen die Variablen eine Bedingung erfüllen müssen z.b $x^2 + y^2 \leq 1$, dann bekommt man die Grenzen des Integrals durch das umformen der jeweiligen Variabel.
Z.b. Um $f_X(x)$ zu erhalten (nach y integrieren): $y^2 \leq 1 - x^2 \Rightarrow y = \pm \sqrt{1 - x^2}$ Obere Grenze $+\sqrt{1 - x^2}$ Untere Grenze $-\sqrt{1 - x^2}$ Falls Grenzen nicht beschränkt sind einfach nach ∞ integrieren z.b. mit $0 < x < y$ gilt $f_Y = \int_x^\infty f_{X,Y}(x, y) dy$

Grenzwertsätze

S 6.2. (Schwaches Gesetz der grossen Zahlen) : Sei X_1, X_2, \dots eine Folge von unabhängigen Zufallsvariablen mit gleichen Erwartungswerten $\mathbb{E}[X_k] = \mu$ und Varianzen $\mathbb{V}[X_k] = \sigma^2$. Sei

$$\bar{X}_n = \frac{1}{n} S_n = \frac{1}{n} \sum_{k=1}^n X_k$$

Dann konvergiert \bar{X}_n für $n \rightarrow \infty$ in Wahrscheinlichkeit gegen $\mu = \mathbb{E}[X_k]$, d.h. für jedes $\varepsilon > 0$ gilt

$$\mathbb{P} \left[\left| \bar{X}_n - \mu \right| \varepsilon \right] \xrightarrow{n \rightarrow \infty} 0$$

Note :

- X_i, X_j unkorreliert $\Leftrightarrow \text{Cov}(X_i, X_j) = 0$
- X_i, X_j unabhängig $\Rightarrow X_i, X_j$ unkorreliert

S 6.5. (Starkes Gesetz der grossen Zahlen): Sei X_1, X_2, \dots eine Folge von unabhängigen Zufallsvariablen, die alle dieselbe Verteilung haben mit endlichem Erwartungswert $\mathbb{E}[X_k]$. Für

$$\bar{X}_n = \frac{1}{n} S_n = \frac{1}{n} \sum_{k=1}^n X_k$$

gilt dann

$$\bar{X}_n \xrightarrow{n \rightarrow \infty} \mu \quad \text{\textbf{P-fast sicher}},$$

das bedeutet,

$$\mathbb{P} \left[\left\{ \omega \in \Omega \mid \bar{X}_n(\omega) \xrightarrow{n \rightarrow \infty} \mu \right\} \right] = 1.$$

Def 6.7. (Konvergenz in Verteilung): Seien $(X_n)_{n \in \mathbb{N}}$ und X Zufallsvariablen mit Verteilungsfunktionen $(F_n)_{n \in \mathbb{N}}$ und F . Wir sagen $(X_n)_{n \in \mathbb{N}}$ konvergiert in Verteilung gegen X und schreiben

$$X_n \xrightarrow{d} X \text{ für } n \rightarrow \infty$$

falls für jeden Stetigkeitspunkt $x \in \mathbb{R}$ von F gilt,

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} \mathbb{P}[X_n \leq x] = \mathbb{P}[X \leq x] = F(x)$$

In der Literatur findet man unter anderem folgende Notation,

$$X_n \xrightarrow{w} X \text{ und } X_n \xrightarrow{L} X.$$

Die Buchstaben d, w, L stehen dabei für "convergence in distribution", "weak convergence", bzw. "convergence in law".
S 6.10. (zentraler Grenzwertsatz, ZGS) : Sei $(X_k)_{k \in \mathbb{N}}$ eine Folge von i.i.d. Zufallsvariablen mit $\mathbb{E}[X_k] = \mu$ und $\mathbb{V}[X_k] = \sigma^2$. Für die Partialsummen $S_n = \sum_{k=1}^n X_k$ gilt dann für alle $x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left[\frac{S_n - n\mu}{\sigma \sqrt{n}} \leq x \right] = \Phi(x)$$

wobei Φ die Verteilungsfunktion der $\mathcal{N}(0, 1)$ -Verteilung ist. und somit $\frac{1}{n} \frac{S_n - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{S_n - n\mu}{\sigma \sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$

Def 6.16. (Momenterzeugende Funktion) :
Die momenterzeugende Funktion einer Zufallsvariablen X ist für $t \in \mathbb{R}$ definiert durch

$$M_X(t) = \mathbb{E} \left[e^{tX} \right] \stackrel{\text{S4.18}}{=} \int_{-\infty}^{\infty} e^{tx} f_X(x) dx$$

S 6.19. (Chernoff-Ungleichung): Seien X_1, \dots, X_n i.i.d. Zufallsvariablen, für welche die momenterzeugende Funktion $M_X(t)$ für alle $t \in \mathbb{R}$ endlich ist. Für jedes $b \in \mathbb{R}$ gilt dann

$$\mathbb{P}[S_n \geq b] \leq \exp \left(\inf_{t \in \mathbb{R}} (n \log M_X(t) - tb) \right)$$

S 6.20. (Chernoff-Schranke): Seien X_1, \dots, X_n unabhängig mit $X_k \sim \text{Ber}(p_k)$ und sei $S_n = \sum_{k=1}^n X_k$. Sei $\mu_n = \mathbb{E}[S_n] = \sum_{k=1}^n p_k$ und $\delta > 0$, dann gilt

$$\mathbb{P}[S_n \geq (1 + \delta)\mu_n] \leq \left(\frac{e^\delta}{(1 + \delta)^{1 + \delta}} \right)^{\mu_n}$$

Statistik

Def 7.2. (Schätzer) : Ein Schätzer ist eine Zufallsvariable der Form

$$T_\ell = t_\ell(X_1, \dots, X_n)$$

Die Schätzfunktionen $t_\ell : \mathbb{R}^n \rightarrow \mathbb{R}$ müssen noch gewählt/gefunden werden. Einsetzen von Daten $x_k = X_k(\omega), k = 1, \dots, n$, liefert dann Schätzwerte $T_\ell(\omega) = t_\ell(x_1, \dots, x_n)$ für $\vartheta_\ell, \ell = 1, \dots, m$. Der Kürze halber schreiben wir oft auch $T = (T_1, \dots, T_m)$ und $\vartheta = (\vartheta_1, \dots, \vartheta_m)$.
Note Fehler: Die Entscheidung bei einem Test kann auf zwei verschiedene Arten falsch herauskommen:
• Fehler 1. Art: die Hypothese wird abgelehnt, obwohl sie richtig ist. Das passiert für $\vartheta \in \Theta_0$ und $T \in K$. $\mathbb{P}_\vartheta[T \in K]$ heisst für $\vartheta \in \Theta_0$ die Wahrscheinlichkeit für einen Fehler 1. Art.
• Fehler 2. Art: die Hypothese wird angenommen, obwohl sie falsch ist. Das passiert für $\vartheta \in \Theta_A$ und $T \notin K$. $\mathbb{P}_\vartheta[T \notin K] = 1 - \mathbb{P}_\vartheta[T \in K]$ heisst für $\vartheta \in \Theta_A$ die Wahrscheinlichkeit für einen Fehler 2. Art.

Def 7.5. (Erwartungstreue): Ein Schätzer T heisst erwartungstreu für ϑ , falls für alle $\vartheta \in \Theta$ gilt

$$\mathbb{E}_\vartheta[T] = \vartheta$$

Def 7.6. (Bias und MSE) : Sei $\vartheta \in \Theta$ und T ein Schätzer. Der Bias (oder erwartete Schätzfehler) von T im Modell \mathbb{P}_ϑ ist definiert als

$$\mathbb{E}_\vartheta[T] - \vartheta$$

Erwartungstreu bedeutet also, dass der Bias gleich Null ist. Der mittlere quadratische Schätzfehler von T im Modell \mathbb{P}_ϑ ist definiert als

$$\text{MSE}_\vartheta[T] = \mathbb{E}_\vartheta \left[(T - \vartheta)^2 \right]$$

Note MSE: Man kann den MSE in folgender Form zerlegen.

$$\text{MSE}_\vartheta[T] = \text{Var}_\vartheta[T] + (\mathbb{E}_\vartheta[T] - \vartheta)^2$$

Def Konsistenz: Eine Folge von Schätzern $T^{(n)}, n \in \mathbb{N}$, heisst **konsistent** für ϑ , falls $T^{(n)}$ für $n \rightarrow \infty$ in \mathbb{P}_ϑ -Wahrscheinlichkeit gegen ϑ konvergiert, d.h. für jedes $\vartheta \in \Theta$ und jedes $\varepsilon > 0$ gilt

$$\lim_{n \rightarrow \infty} \mathbb{P}_\vartheta \left[\left| T^{(n)} - \vartheta \right| > \varepsilon \right] = 0$$

Def 7.9. (Likelihood-Funktion) : Die Likelihood-Funktion ist

$$L(x_1, \dots, x_n; \vartheta) = \begin{cases} p_{\vec{x}}(x_1, \dots, x_n; \vartheta) & \text{diskret} \\ f_{\vec{x}}(x_1, \dots, x_n; \vartheta) & \text{stetig} \end{cases}$$

Die Funktion $\log L(x_1, \dots, x_n; \vartheta)$ heisst log-Likelihood-Funktion und hat im i.i.d.-Fall den Vorteil durch eine Summe gegeben zu sein.
Def 7.10. (ML-Schätzer): Der Maximum-Likelihood-Schätzer T_{ML} für ϑ wird dadurch definiert, dass er die Funktion

$$\vartheta \mapsto L(X_1, \dots, X_n; \vartheta)$$

über alle ϑ maximiert, d.h.

$$T_{\text{ML}} = t_{\text{TM}}(X_1, \dots, X_n) \in \arg \max_{\vartheta \in \Theta} L(X_1, \dots, X_n; \vartheta)$$

RC Log-MLE:
Gegeben seien $X_1 \dots X_n$ unter P_ϑ i.i.d. Für ein fixes n gilt: (falls n bekannt, gleich einsetzen)

1. Gemeinsame Dichte finden $g(x_1, \dots, x_n) = \prod_{i=1}^n \mathbb{P}[X_i = x_i]$
2. Bestimme $f(\vartheta) = \log(L(x_1, \dots, x_n; \vartheta))$ (ϑ einsetzen für respective Variable in allen Verteilungen)
3. Maximum von $f(\vartheta)$ finden ($f(\vartheta)' = 0$ und $f(\vartheta)'' < 0$, Ränder Überprüfen)

RC Erwartungstreue eines Schätzers:
Berechne $\mathbb{E}_\lambda[T] - \lambda$. Falls 0, dann ist Schätzer Erwartungstreu. Da X_i i.i.d sind kann man Linearität des Erwartungswertes anwenden.

RC Konsistenz eines Schätzers:
Benutze Chebyshev

$$\mathbb{P}_p[|T_n - \lambda| > \varepsilon] \leq \frac{\text{Var}(T_n)}{\varepsilon^2}$$

Varianz des Schätzers durch Proposition 4.46 ausrechnenbar, da i.i.d.
Falls $\lim_{n \rightarrow \infty} \frac{\text{Var}(T_n)}{\varepsilon^2} = 0$ dann konsistent

Note MLE-Schätzer:
• $X_1, \dots, X_n \sim \text{Ber}(\theta)$ iid.: $T = \frac{1}{n} \sum_{i=1}^n X_i$
• $X_1, \dots, X_n \sim \text{Exp}(\theta)$ iid.: $T = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}_n$
• $X_1, \dots, X_n \sim \text{Geo}(\theta)$ iid.: $T = \frac{\sum_{i=1}^n X_i}{n} = \frac{1}{\bar{X}_n}$
• $X_1, \dots, X_n \sim \text{Bin}(N, \theta)$ iid.: $T = \frac{1}{N} \frac{\sum_{i=1}^n X_i}{n} = \bar{X}_n$
• $X_1, \dots, X_n \sim \text{Poi}(\theta)$ iid.: $T = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}_n$
• $X_1, \dots, X_n \sim \mathcal{U}([\theta_1, \theta_2])$ iid.:
 $T_{\theta_1} = \max(X_i), T_{\theta_2} = \min(X_i)$
• $X_1, \dots, X_n \sim \mathcal{N}(\theta_1, \theta_2)$ iid. :
 $T_{\theta_1} = \bar{X}_n, T_{\theta_2} = S^2$
Def 7.18. (Studentische t-Verteilung): Eine stetige Zufallsvariable X heisst t -verteilt mit m Freiheitsgraden falls ihre Dichte für $x \in \mathbb{R}$ gegeben ist durch

$$f_X(x) = \frac{\Gamma\left(\frac{m+1}{2}\right)}{\sqrt{m\pi}\Gamma\left(\frac{m}{2}\right)} \left(1 + \frac{x^2}{m}\right)^{-\frac{m+1}{2}}$$

Wir schreiben dann $X \sim t_m$.
S 7.20.:
Seien X_1, \dots, X_n i.i.d. $\sim \mathcal{N}(\mu, \sigma^2)$, und

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k, \quad S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X}_n)^2$$

Es gelten folgende Aussagen:

1. $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{1}{n}\sigma^2\right)$, also $\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$.
2. $\frac{n-1}{\sigma^2} S^2 = \frac{1}{\sigma^2} \sum_{k=1}^n (X_k - \bar{X}_n)^2 \sim \chi_{n-1}^2$.
3. \bar{X}_n und S^2 sind unabhängig.
4. $\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{1}{n-1} \frac{n-1}{\sigma^2} S^2}} \sim t_{n-1}$.

Testing

Def Entscheidungsregel: Die Hypothese H_0 wird verworfen, wenn $T(\omega) \in K$, Die Hypothese H_0 wird nicht verworfen bzw. angenommen, wenn $T(\omega) \notin K$
Def Signifikanzniveau: Für einen Test wählt zuerst ein Signifikanzniveau $\alpha \in (0, 1)$ und verlangt

$$\sup_{\vartheta \in \Theta_0} \mathbb{P}_\vartheta[T \in K] \leq \alpha.$$

Man kontrolliert also die Wahrscheinlichkeit für einen Fehler 1. Art durch α . Für $\alpha \downarrow$ gilt
• Prob für Fehler 1. Art wird kleiner
• Verwerfungsbereich muss kleiner gewählt werden
• Prob für Fehler 2. Art wird grösser
• Macht des Tests wird kleiner

Def 8.7. (Likelihood-Quotient): Für $\vartheta_0 \in \Theta_0, \vartheta_A \in \Theta_A$ und $x_1, \dots, x_n \in \mathbb{R}$ definieren wir den Likelihood-Quotienten durch

$$R(x_1, \dots, x_n; \vartheta_0, \vartheta_A) = \frac{L(x_1, \dots, x_n; \vartheta_A)}{L(x_1, \dots, x_n; \vartheta_0)}.$$

Als Konvention setzen wir $R(x_1, \dots, x_n; \vartheta_0, \vartheta_A) = +\infty$, wenn $L(x_1, \dots, x_n; \vartheta_0) = 0$
Def 8.8. (Likelihood-Quotienten-Test): Sei $c \geq 0$. Der Likelihood-Quotienten-Test mit Parameter c ist ein Test (T, K) mit Teststatistik $T = R(X_1, \dots, X_n; \vartheta_0, \vartheta_A)$ und Verwerfungsbereich $K = (c, \infty]$.
Lem 8.9. (Neyman-Pearson-Lemma): Sei $\Theta_0 = \{\vartheta_0\}$ und $\Theta_A = \{\vartheta_A\}$. Sei (T, K) ein Likelihood-Quotienten-Test mit Parameter c und Signifikanzniveau $\alpha^* := \mathbb{P}_{\vartheta_0}[T \in K]$. Ist (T', K') ein anderer Test mit Signifkanzniveau $\mathbb{P}_{\vartheta_0}[T' \in K'] =: \alpha \leq \alpha^*$, so gilt auch

$$\mathbb{P}_{\vartheta_A}[T' \in K'] \leq \mathbb{P}_{\vartheta_A}[T \in K].$$

Das bedeutet, jeder andere Test mit kleinerem Signifikanzniveau hat auch kleinere Macht bzw. grössere Wahrscheinlichkeit für einen Fehler 2. Art.
Def 8.10. (Verallgemeinerung des Likelihood-Quotient): Der verallgemeinerte Likelihood-Quotient ist gegeben durch

$$R(x_1, \dots, x_n) = \frac{\sup_{\vartheta \in \Theta_A} L(x_1, \dots, x_n; \vartheta)}{\sup_{\vartheta \in \Theta_0} L(x_1, \dots, x_n; \vartheta)}$$

oder auch

$$\tilde{R}(x_1, \dots, x_n) = \frac{\sup_{\vartheta \in \Theta_A \cup \Theta_0} L(x_1, \dots, x_n; \vartheta)}{\sup_{\vartheta \in \Theta_0} L(x_1, \dots, x_n; \vartheta)}.$$

RC Z-Test:
Gegeben:
• **Daten:** x_i und $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$
• **Nullhypothese :** μ_0
• **Alternativhypothese :**
– $\mu > \mu_0$ (rechtsseitig)
– $\mu < \mu_0$ (linksseitig)
– $\mu \neq \mu_0$ (beidseitig)
• **Signifikanzniveau :** α

1. Berechne Z-Score

$$Z = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

2. Berechne z

- $z = z_{1-\alpha} = \Phi^{-1}(1 - \alpha)$ (rechtsseitig)
- $z = z_\alpha = \Phi^{-1}(\alpha)$ (linksseitig)
- $z_{+,-} = \pm z_{\frac{\alpha}{2}} = \pm \Phi^{-1}(\frac{\alpha}{2})$ (beidseitig)

3. Entscheide:

- $Z > z \implies$ verwurfe μ_0 (rechtsseitig)
- $Z < z \implies$ verwurfe μ_0 (linksseitig)
- $Z > z_+ \vee Z < z_- \implies$ verwurfe μ_0 (beid-seitig)

Aufgaben

Ex : Die Zufallsvariable X habe eine Verteilungsfunktion F_X mit zugehöriger Dichte f_X . Sei $Y = aX + b$, mit $a > 0$ und $b \in \mathbb{R}$. Dann gilt für die Dichte f_Y von Y

Für die Verteilungsfunktion F_Y von Y gilt, dass $F_Y(y) = P[Y \leq y] = P[aX + b \leq y] = P\left[X \leq \frac{y-b}{a}\right] = F_X\left(\frac{y-b}{a}\right)$.

Somit folgt mit der Kettenregel

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} F_X\left(\frac{y-b}{a}\right) = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{a}.$$

Analysis

Note Gamma Funktion: Die Funktion Γ nennt man (Eulersche) Gammafunktion und sie ist für $x \geq 0$ definiert durch

$$\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} \, dt$$

Γ hat eine grundlegende Verbindung zur Fakultätsfunktion, denn

$$\Gamma(n+1) = n! \text{ für } n \in \mathbb{N}_0.$$

Note Partielle Integration:

$$\int f'(x)g(x) \, dx = f(x)g(x) - \int f(x)g'(x) \, dx$$

oder

$$\int_a^b f'(x)g(x) \, dx = |f(x)g(x)|_a^b - \int_a^b f(x)g'(x) \, dx$$

- Note Substitution:** Um $\int_a^b f(g(x)) \, dx$ zu berechnen: Ersetze $g(x)$ durch u und integriere $\int_{g(a)}^{g(b)} f(u) \frac{du}{g'(x)}$.
- $g'(x)$ muss sich herauskürzen, sonst nutzlos.
 - Grenzen substituieren nicht vergessen.
 - Alternativ: unbestimmtes Integral berechnet werden und dann u wieder durch x substituieren.
 - Man kann auch das Theorem in die andere Richtung anwenden:

$$\int_a^b f(u) \, du = \int_{g^{-1}(a)}^{g^{-1}(b)} f(g(x))g'(x) \, dx$$

- Sei Y kompakt, $f : Y \subset \mathbb{R}^n \rightarrow \mathbb{R}$ stetig. Sei $\gamma : [0,1] \rightarrow Y$ mit $\gamma(0) = A, \gamma(1) = B$. Dann gilt $\int_0^1 f(\gamma(t)) \gamma'(t) \, dt = \int_A^B f(x) \, dx$.
- Wenn $\gamma : [0,1] \rightarrow Y$ bijektiv und C^1 mit $\det(J_\gamma(t)) \neq 0, \forall t \in [0,1]$, dann gilt $\int_0^1 f(\gamma(t)) \det(J_\gamma(t)) \, dt = \int_A^B f(x) \, dx$.

$$\int_Y f(y) \, dy = \int f(\gamma(x)) |\det(J_\gamma(x))| \, dx$$

Note Binomialsatz:

$$(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^{n-k} y^k \quad \text{mit:} \quad \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Des weiteren gilt:

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

Note Trigo-Werte:

deg	0	30	45	60	90	180
rad	0	$\frac{\pi}{6}$	$\frac{\pi}{4}$	$\frac{\pi}{3}$	$\frac{\pi}{2}$	π
cos	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	-1
sin	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1	0
tan	0	$\frac{1}{\sqrt{3}}$	1	$\sqrt{3}$	$+\infty$	0

Note Log/Exp Regeln:

Exponential	Logarithm
$a^0 = 1$	$\log_a 1 = 0$
$a^1 = a$	$\log_a a = 1$
$a^{m+n} = a^m \cdot a^n$	$\log_a(xy) = \log_a x + \log_a y$
$a^{m-n} = \frac{a^m}{a^n}$	$\log_a\left(\frac{x}{y}\right) = \log_a x - \log_a y$
$(a^m)^n = a^{mn}$	$\log_a(x^r) = r \log_a x$
$(ab)^m = a^m \cdot b^m$	$\log_a x = \frac{\log_b x}{\log_b a}$
$\left(\frac{a}{b}\right)^m = \frac{a^m}{b^m}$	$\log_a(a^x) = x$
$e^{\ln x} = x$	$\ln(e^x) = x$
	$e^{\ln x} = x \quad (\text{for } x > 0)$

Note Quadratic Form: Für $a^2 + bx + c = 0$ gilt:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

Ableitungen

F(x)	f(x)	f'(x)
$\frac{x^{-a+1}}{-a+1}$	$\frac{1}{x^a}$	$-\frac{a}{x^{a+1}}$
$\frac{x^a+1}{a+1}$	$x^a \ (a \neq -1)$	$a \cdot x^{a-1}$
$\frac{1}{k \ln(a)} a^{kx}$	a^{kx}	$ka^{kx} \ln(a)$
$\ln x $	$\frac{1}{x}$	$-\frac{1}{x^2}$
$\frac{2}{3} x^{3/2}$	\sqrt{x}	$\frac{1}{2\sqrt{x}}$
$\frac{n}{n+1} x^{\frac{1}{n}+1}$	$\sqrt[n]{x}$	$\frac{1}{n} x^{\frac{1}{n}-1}$
$-\cos(x)$	$\sin(x)$	$\cos(x)$
$\sin(x)$	$\cos(x)$	$-\sin(x)$
$\frac{1}{2}(x - \frac{1}{2} \sin(2x))$	$\sin^2(x)$	$2 \sin(x) \cos(x)$
$\frac{1}{2}(x + \frac{1}{2} \sin(2x))$	$\cos^2(x)$	$-2 \sin(x) \cos(x)$
$-\ln \cos(x) $	$\tan(x) = \frac{\sin}{\cos}$	$\frac{1}{\cos^2(x)}$
$\cosh(x)$	$\sinh(x)$	$\cosh(x)$
$\log(\cosh(x))$	$\tanh(x)$	$\frac{1}{\cosh^2(x)}$
$\ln \sin(x) $	$\cot(x)$	$-\frac{1}{\sin^2(x)}$
$\frac{1}{c} \cdot e^{cx}$	e^{cx}	$c \cdot e^{cx}$
$x(\ln x - 1)$	$\ln x $	$\frac{1}{x}$
$\frac{1}{2}(\ln(x))^2$	$\frac{\ln(x)}{x}$	$\frac{1-\ln(x)}{x^2}$
$\frac{x}{\ln(a)} (\ln x - 1)$	$\log_a x $	$\frac{1}{\ln(a)x}$

F(x)	f(x)
$\frac{1}{a \cdot (n+1)} (ax+b)^{n+1}$	$(ax+b)^n$
$\arcsin(x)$	$\frac{1}{\sqrt{1-x^2}}$
$\arccos(x)$	$\frac{-1}{\sqrt{1-x^2}}$
$\arctan(x)$	$\frac{1}{1+x^2}$
$\operatorname{arcsinh}(x)$	$\frac{1}{\sqrt{1+x^2}}$
$\operatorname{arccosh}(x)$	$\frac{1}{\sqrt{x^2-1}}$
$\operatorname{arctanh}(x)$	$\frac{1}{1-x^2}$
$x^x \ (x > 0)$	$x^x \cdot (1 + \ln x)$
$\log_a x $	$\frac{1}{x \ln a} = \log_a(e) \frac{1}{x}$

Integrale

f(x)	F(x)
$\int f'(x)f(x)$	$\frac{1}{2}(f(x))^2$
$\int \frac{f'(x)}{f(x)}$	$\ln f(x) $
$\int_{-\infty}^{\infty} e^{-x^2}$	$\sqrt{\pi}$
$\int (ax+b)^n$	$\frac{1}{a(n+1)}(ax+b)^{n+1}$
$\int x(ax+b)^n$	$\frac{(ax+b)^{n+2}}{(n+2)a^2} - \frac{b(ax+b)^{n+1}}{(n+1)a^2}$
$\int (ax^p+b)^n x^{p-1}$	$\frac{(ax^p+b)^{n+1}}{ap(n+1)}$
$\int (ax^p+b)^{-1} x^{p-1}$	$\frac{1}{ap} \ln ax^p+b $
$\int \frac{ax+b}{cx+d}$	$\frac{ax}{c} - \frac{ad-bc}{c^2} \ln cx+d $
$\int \frac{1}{x^2+a^2}$	$\frac{1}{a} \arctan \frac{x}{a}$
$\int \frac{1}{x^2-a^2}$	$\frac{1}{2a} \ln \left \frac{x-a}{x+a} \right $
$\int \sqrt{a^2+x^2}$	$\frac{x}{2} f(x) + \frac{a^2}{2} \ln(x+f(x))$
$\int \frac{1}{(x+a)^2} dx$	$-\frac{1}{a+x}$
$\int \frac{1}{(x+a)^3} dx$	$-\frac{1}{2(a+x)^2}$
$\int \frac{(x+a)^t}{(x+a)^2} dx$	$\frac{(1-t)(x+a)^{t+1}}{a}$
$\int \frac{x}{(x+a)^2} dx$	$\frac{a}{a+x} + \log a+x $
$\int \frac{x}{(x+a)^3} dx$	$-\frac{a+2x}{2(a+x)^2}$
$\int \frac{1}{ax^2+bx+c} dx$	$2 \arctan\left(\frac{2ax+b}{\sqrt{4ac-b^2}}\right)$
$\int \sin(kx) \cdot \cos(kx) dx$	$-\frac{1}{4k} \cos(2kx) = \frac{-(\cos(x))^2}{2}$
$\int \cos^n(x) dx$	$\frac{n-1}{n} \int \cos^{n-2}(x) dx + \frac{\cos^{n-1}(x) \sin(x)}{n}$
$\int \sin^n(x) dx$	$\frac{n-1}{n} \int \sin^{n-2}(x) dx - \frac{\cos(x) \sin^{n-1}(x)}{n}$
$\int \sin \cos dx$	$-\frac{1}{2} \cos^2$
$\int \frac{\cos}{\sin} dx$	$\log(\cos(x))$

Aufgabe 1

Seien U_1, U_2, U_3 i.i.d. $\text{Uni}([0, 1])$ Zufallsvariablen. Wir definieren $L = \min(U_1, U_2, U_3)$ und $M = \max(U_1, U_2, U_3)$.

Berechne die Wahrscheinlichkeitsdichte von M .

$$F_M(m) = \mathbb{P}[U_1 \leq m, U_2 \leq m, U_3 \leq m] = \Pi_{i=1}^3 \mathbb{P}[U_i \leq m]$$

Berechne die gemeinsame Wahrscheinlichkeitsdichte von L und M .

$$\begin{aligned} P[M < m, L \leq l] \\ = P[M < m] - P[M < m, L > l] \\ = m^3 - P[l < U_1 < m, l < U_2 < m, l < U_3 < m] \\ = m^3 - (P[l < U_1 < m])^3 = m^3 - (m-l)^3 \\ \text{für } 0 \leq l \leq m \leq 1 \\ \text{So } f_{M,L}(m, L) = 6(m-l)^2 \mathbb{1}_{\{0 \leq l \leq m \leq 1\}}. \end{aligned}$$

Generell gilt:

$$F_{\text{Max}(X,Y)}(z) = P(X \leq z) \cdot P(Y \leq z) = F_X(z) \cdot F_Y(z)$$

Oder

$$F_{\text{Min}(X,Y)}(z) = P(X \leq z) + P(Y \leq z) - P(X \leq z, Y \leq z)$$

und dann

$$f_{\text{Max}(X,Y)}(z) = \frac{d}{dz} F_{\text{Max}(X,Y)}(z)$$

Verteilung	Parameter	$\mathbb{E}[X]$	$\mathbb{V}(X)$	$p_X(t)$	$F_X(t) = \mathbb{P}[X \leq t]$
Bernoulli $\sim \text{Ber}(p)$	p : ErfolgsWK	p	$p \cdot (1 - p)$	$p^t(1 - p)^{1-t}$	$1 - p$ für $0 \leq t < 1$
Binomial $\sim \text{Bin}(n, p)$	n : Anzahl Versuche, p : ErfolgsWK	np	$np(1 - p)$	$\binom{n}{t} p^t (1 - p)^{n-t}$	$\sum_{k=0}^t \binom{n}{k} p^k (1 - p)^{n-k}$
Geometrisch $\sim \text{Geo}(p)$	p : ErfolgsWK, t : Anzahl Versuche	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$p(1 - p)^{t-1}$	$1 - (1 - p)^t$
Negativbinomial $\sim \text{NegBin}(r, p)$	r : Anzahl der Erfolge, p : Erfolgswahrscheinlichkeit	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	$\binom{t+r-1}{t} p^t (1 - p)^r$	$I_{1-p}(r, t + 1)$
Hypergeometrisch $\sim \text{H}(N, M, n)$	N : Gesamtzahl, M : Anzahl der Erfolge, n : Zufallsstichprobe	$n \frac{M}{N}$	$n \frac{M}{N} \frac{N-M}{N} \frac{N-n}{N-1}$	$\frac{\binom{M}{t} \binom{N-M}{n-t}}{\binom{N}{n}}$	$\frac{\sum_{k=0}^t \binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$
Poisson $\sim \text{Poi}(\lambda)$	λ : Erwartungswert λ : Varianz	λ	λ	$\frac{\lambda^t}{t!} e^{-\lambda}$	$e^{-\lambda} \sum_{k=0}^t \frac{\lambda^k}{k!}$
Gleichverteilung $\sim \mathcal{U}([a, b])$	n : Anzahl Ereignisse x_i : Ereignisse	$\frac{1}{n} \sum_{i=1}^n x_i$	$\frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n^2} (\sum_{i=1}^n x_i)^2$	$\frac{1}{n}$	$\frac{ \{k: x_k \leq t\} }{n}$
Gleichverteilung $\sim \mathcal{U}([a, b])$ (Intervall)	$[a, b]$: Intervall	$\frac{a+b}{2}$	$\frac{1}{12}(b - a)^2$	$\begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{sonst} \end{cases}$	$\begin{cases} 0 & x \leq a \\ \frac{t-a}{b-a} & a < x < b \\ 1 & x \geq b \end{cases}$
Exponentialverteilung $\sim \text{Exp}(\lambda)$	$\lambda : \frac{1}{\mathbb{E}[X]}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\begin{cases} \lambda e^{-\lambda t} & t \geq 0 \\ 0 & t < 0 \end{cases}$	$\begin{cases} 1 - e^{-\lambda t} & t > 0 \\ 0 & t \leq 0 \end{cases}$
Cauchyverteilung $\sim \text{Cauchy}(x_0, \gamma)$	x_0 : Lageparameter, γ : Skalenparameter	Undefiniert	Undefiniert	$\frac{1}{\pi \gamma \left[1 + \left(\frac{t-x_0}{\gamma}\right)^2\right]}$	$\frac{1}{\pi} \arctan\left(\frac{t-x_0}{\gamma}\right) + \frac{1}{2}$
Normalverteilung $\sim \mathcal{N}(\mu, \sigma^2)$	σ^2 : Varianz, $\mu : \mathbb{E}[X]$	μ	σ^2	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}$	$\frac{1}{2} \left[1 + \text{erf}\left(\frac{t-\mu}{\sigma\sqrt{2}}\right)\right]$
χ^2 -Verteilung $\sim \chi_n^2$	n : Freiheitsgrad	n	$2n$	$\frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} t^{\frac{n}{2}-1} e^{-\frac{t}{2}}$ für $t > 0$	$\text{Poi}\left(\frac{n}{2}, \frac{t}{2}\right)$
t-Verteilung $\sim t_n$	n : Freiheitsgrad	$\begin{cases} 0 & n > 1 \\ \text{undef.} & \text{sonst} \end{cases}$	$\begin{cases} \frac{n}{n-2} & n > 2 \\ \infty & 1 < n \leq 2 \\ \text{undef.} & \text{sonst} \end{cases}$	$\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \cdot \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$	Undefiniert